


(ist1105940, ist1106221)

I. Pen-and-paper

1) [5v] Complete the given decision tree using Shannon entropy (*log*2) and considering that: i) a minimum of 4 observations is required to split an internal node, and ii) decisions by ascending alphabetic should be placed in case of ties.

If
$$(y_1)_{x_1,x_2,x_3} = H(y_0,x_1) - H(y_0,x_1) + H(y_$$



Homework I – Group 51 (ist1105940, ist1106221)

2) [2.5v] Draw the training confusion matrix for the learnt decision tree.

3) [1.5v] Identify which class has the lowest training F1 score.

$$F = \frac{2}{P} + \frac{1}{R}$$

$$P = \frac{TP}{TP + NP}$$

$$Clooke A:$$

$$R = \frac{2}{3}$$

$$Close B:$$

$$R = 1$$

$$R = \frac{5}{6}$$


$$P = \frac{5}{5}$$

$$R = 0,909$$

$$Response: A look the localest training F1 page.$$

(ist1105940, ist1106221)

4) [1v] Draw the class-conditional relative histograms of y1 using 5 equally spaced bins in [0,1]. Find the *n*-ary root split using the discriminant rules from these empirical distribution





(ist1105940, ist1106221)


II. Programming and critical analysis


1) [1v] ANOVA is a statistical test that can be used to assess the discriminative power of a single input variable. Using f_classif from sklearn, identify the input variables with the worst and best discriminative power. Plot their class-conditional probability density functions.

2)

```
import pandas as pd
from sklearn.feature_selection import f_classif
from scipy.io.arff import loadarff
data = loadarff('diabetes.arff')
df = pd.DataFrame(data[0])
df['Outcome'] = df['Outcome'].str.decode('utf-8')
# Separate features from the outcome (class)
 = df.drop('Outcome', axis=1)
  = df['Outcome']
fcalss = f_classif(X, y)
best_index = fcalss[0].argmax()
worst_index = fcalss[0].argmin()
best_power, worst_power = X.columns[best_index], X.columns[worst_index]
print('Input variable with the best discriminative power:',best_power)
print('Input variable with the worst discriminative power:', worst_power)
classes = df['Outcome'].unique()
plt.figure(figsize=(12, 7))
for target_class in classes:
    subset = df[df['Outcome'] == target_class]
    sns.kdeplot(subset[best_power], label=f'Outcome {target_class}')
plt.xlabel(best_power)
plt.ylabel('Density')
plt.title(f'Class-Conditional Probability Density for {best_power}')
plt.legend(title='Outcome')
plt.show()
plt.figure(figsize=(12, 7))
for target_class in classes:
    subset = df[df['Outcome'] == target_class]
sns.kdeplot(subset[worst_power], label=f'Outcome {target_class}')
plt.xlabel(worst_power)
plt.vlabel('Density')
plt.title(f'Class-Conditional Probability Density for {worst_power}')
plt.legend(title='Outcome')
plt.show()
```

Input variable with the best discriminative power: Glucose
Input variable with the worst discriminative power: BloodPressure








(ist1105940, ist1106221)

2) [4v] Using a stratified 80-20 training-testing split with a fixed seed (random_state=1), assess in a single plot both the training and testing accuracies of a decision tree with minimum sample split in {2, 5,10, 20, 30, 50, 100} and the remaining parameters as default. [optional] Note that split thresholding of numeric variables in decision trees is nondeterministic in sklearn, hence you may opt to average the results using 10 runs per parameterization.

```
from sklearn.model_selection import train_test_split
from the same train import DecisionTracClassifier
same train import august as an import manapara and import manapara august as an import manapara august august as an import manapara august august
```





Aprendizagem 2024/25

Homework I – Group 51 (ist1105940, ist1106221)

3) [2v] Critically analyze these results, including the generalization capacity across settings.

Com valores muito baixos de "Min Samples Split" (por exemplo, em torno de 2), o modelo opera em overfitting, levando a um nível muito alto de acurácia no treinamento, quase 100%. No entanto, o lado negativo é que a acurácia de teste é baixa (aproximadamente 70%). Quando o desempenho no treinamento é alto, mas o desempenho no teste é baixo, isso indica que o modelo está excessivamente dependente dos dados de treinamento e não consegue se generalizar bem para novos dados detetando muito ruido.

À medida que o valor de "Min Samples Split" aumenta, a estrutura do modelo tende a se simplificar, o que leva a uma queda lenta na acurácia do treinamento. A partir deste ponto, até ao valor de 40 para "Min Samples Split", a acurácia de teste sobe progressivamente, atingindo sua eficácia máxima ao redor de 40, onde o modelo generaliza melhor. Neste estágio, a diferença entre as acurácias de treinamento e de teste é pequena, sendo este o ponto ideal de complexidade do modelo. O modelo, nesta fase, captura os padrões relevantes sem sofrer de overfitting.


Se o valor de "Min Samples Split" for maior que 50, a acurácia de treinamento e de teste começam a diminuir, indicando que o modelo está sofrendo de underfitting. Ou seja, o modelo se torna tão simplificado que nem consegue se ajustar adequadamente os dados de treinamento. Isso resulta em uma diminuição do desempenho tanto com os dados de treinamento quanto os de teste.



(ist1105940, ist1106221)

4) [2v] To deploy the predictor, a healthcare provider opted to learn a single decision tree (random_state=1) using all available data and ensuring that the maximum depth would be 3 in order to avoid overfitting risks. i. Plot the decision tree.

```
from scipy.io.arff import loadarff
from sklearn.tree import plot_tree, DecisionTreeClassifier
import pandas as pd
import matplotlib.pyplot as plt
# Reading file
data = loadarff('diabetes.arff')
df = pd.DataFrame(data[0])
df['Outcome'] = df['Outcome'].str.decode('utf-8')
X = df.drop('Outcome', axis=1)
y = df['Outcome']
predictor = DecisionTreeClassifier(max_depth=3, random_state=1)
predictor.fit(X, y)
class_names = df['Outcome'].unique()
figure = plt.figure(figsize=(14, 6))
plot_tree(predictor, feature_names=X.columns,
class_names=class_names, impurity=False)
plt.show()
```



TÉCNICO LISBOA

Aprendizagem 2024/25

Homework I – Group 51 (ist1105940, ist1106221)

ii. Explain what characterizes diabetes by identifying the conditional associations together with their posterior probabilities.

Se o nível de glicose for menor ou igual a 127.5, a probabilidade de diabetes é alta. Essa regra baseia-se no seu primeiro nó de decisão, onde um nível de glicose abaixo de 127.5 leva a uma probabilidade alta de diabetes.

Se a idade for menor ou igual a 28.5 e o nível de glicose for maior que 127.5, a probabilidade de diabetes ainda pode ser alta, mas outros fatores como o IMC podem influenciar.

Essa regra considera a interação entre idade e nível de glicose, como indicado na sua árvore.

Se o IMC for maior que 29.95 e o nível de glicose for maior que um determinado valor (por exemplo, 145.5), a probabilidade de diabetes é alta.

Essa regra destaca a importância do IMC, especialmente em combinação com níveis elevados de glicose.

Em suma, o nível de glicose é o principal indicador: Valores altos de glicose estão fortemente associados à diabetes.

Idade e IMC também são importantes: Pessoas mais jovens e com IMC elevado tendem a ter maior risco. A combinação de diferentes fatores (idade, glicose, IMC) pode aumentar ou diminuir o risco de diabetes.